

Работа с СУБД **SQL** Индексы.

Меня хорошо видно && слышно?

Проверка

- настройка микрофона и аудио
- проверка работы чата



Индексы. Структуры данных.

Индекс

- служебная структура данных
- некий способ отображения ключа в данные
- ускоряют поиск, сортировку
- требуют доп. место для хранения
- обновляются при вставке (модификации данных)

Пример из жизни - оглавление

Индекс Данные Ключ 1 Запись 1 P2 Ключ 2 Запись 2 Ключ N PN Запись N

Какие индексы бывают

Уникальные	Не уникальные
Простые	Составные
Кластерные	Некластерные

Вопрос

Много индексов - хорошо или не очень?

Применимость

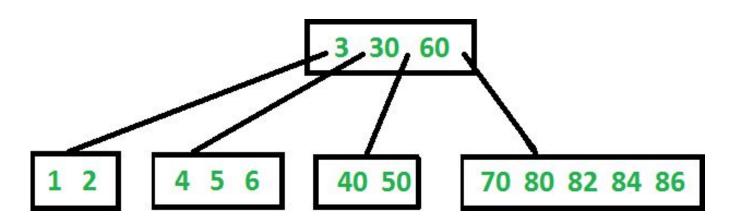
- Ускоряют запросы
- Позволяют делать constraints (UNIQUE, FOREIGN KEY)

У нас много данных

- оперативная память очень ограничена
- будем использовать внешний носитель (привет, медленный HDD)
- logN обращений к медленной памяти

Можем ли мы придумать что-то лучше?!

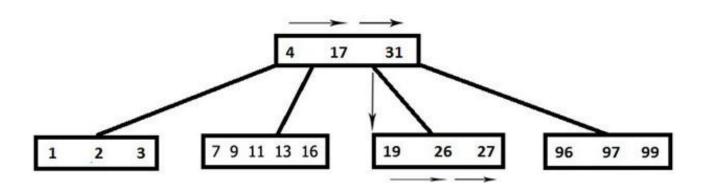
B-tree



Характеристики

- сильно ветвистое сбалансированное дерево
- t минимальная степень
- минимум t 1, не более 2t -1 ключей (кроме корневого) небольшая высота дерева

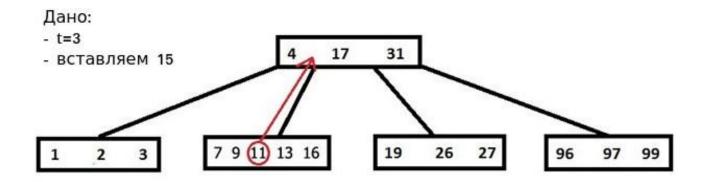
Поиск в B-tree



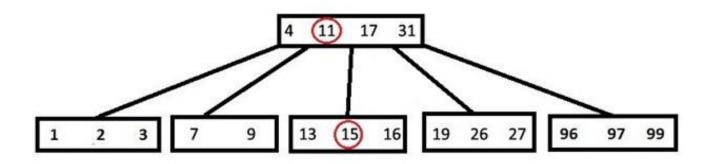
Поиск в B-tree

- алгоритм аналогичен бинарному, но дальнейший выбор не из 2х, а из нескольких
- поиск за O(t logt(n))
- НО обращений к диску O(logt(n))

Добавление в B-tree



Добавление в B-tree



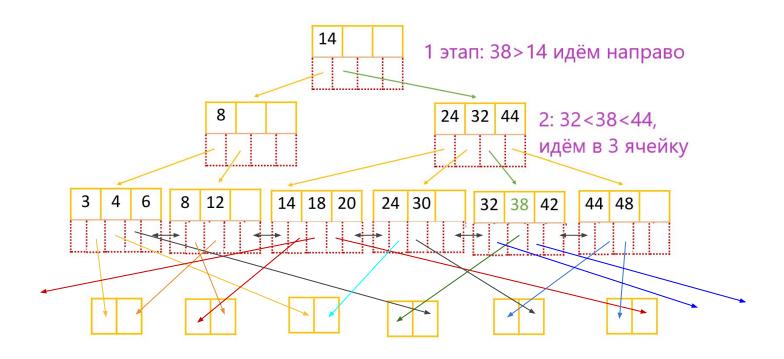
Добавление в B-tree

- нельзя добавить ключ в уже заполненный узел
- разбиение на 2 по t-1 элементу может
- привести к увеличение высоты
- добавление за O(t logt(n))
- НО обращений к диску O(logt(n))

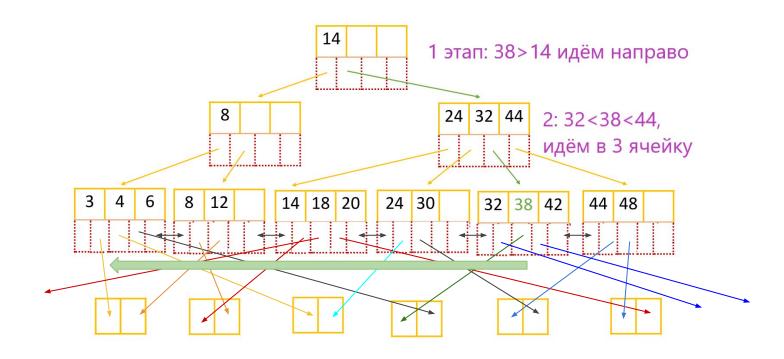
Какой t мне взять?

- больше t => меньше высота дерева
- зависит от размера блока на диске
- зависит от объема оперативной памяти
- обычно от 50 до 2000
- t=1001 и 1млрд записей => 3 операции для любого ключа

B+tree. Поиск по равенству = 38



В+tree. Поиск по неравенству < 38



Индексы в Postgres

- Btree
- Hash
- GIST
- SP-GIST
- GIN
- BRIN
- Функциональные
- Частичные

Составные индексы

- Индекс может быть многоколоночным
- Порядок столбцов в индексе ВАЖЕН
- В дерево пишется весь кортеж (5, 3, 4)
- Правило сравнения работает слева-направо: (1, 2, 3) < (1, 3, 1)
- Выбирайте индекс с большим количеством полей: (usr_id) и (usr_id, added)

Кейс

- Сайт состоит из постов и комментариев к ним
- Таблица с постами
- Таблица с комментариями (comment_id (PK), post_id, time, author,
 ...)
- Пользователь жалуется, что сайт при попытке посмотреть комментарии к посту тормозит
- Что можно сделать с базой?

Решение

Сделаем в качестве PK (post_id, comment_id)

Kak Postgres использует индексы?

- Поиск данных
- Сортировка
- Избежание чтения из таблицы (покрывающие/covering индексы)
- Специальные оптимизации

Проектирование

- uuid text 32 байта uuid uuid 16 байт
- Меньше индексов лучше
- Меньше джойнов лучше
- Составные типы данных вместо отдельных таблиц

Покрывающий индекс

Если решили идти по индексу, а он содержит уже все необходимые данные, то в таблицу не лезем.

Можно включить неиндексируемые поля с помощью INCLUDE

Кластерный индекс

В результате кластеризации таблицы её содержимое физически переупорядочивается в зависимости от индекса. Кластеризация является одноразовой операцией: последующие изменения в таблице нарушают порядок кластеризации

https://www.postgresql.org/docs/current/sql-cluster.html

Готовим данные

```
CREATE TABLE tbl (
id SERIAL NOT NULL PRIMARY KEY,
a bigint NOT NULL,
b bigint NOT NULL,
c bigint NOT NULL,
d bigint NOT NULL,
e bigint NOT NULL,
str text NOT NULL
);
INSERT INTO tbl (a,b,c,d,e,str)
SELECT random()*1000, random()*1000, random()*1000, random()*1000, random():text
FROM generate_series(1, 200000) s(i);
```

```
create index a on tbl(a);
select a, b from tbl where a = 1
create index a_b on tbl(a,b);
select a, b from tbl where a=1 and b=3;
```

- Поиск работает по префиксам индексов.
- Используем explain!

create index a_b_c on tbl(a, b, c)

Хорошие запросы: where

- a=0
- a>0
- a=0 and b>4
- a=0 and b=2
- a=0 and b=2 and c>4
- a = 0 and b in (2, 4) and c > 3

Плохие запросы: where

- b = 6
- b > 3

Частичное использование индексов:

- a>0 and b=4
- a=0 and b>3 and c=2
- a=0 and b>2 and c>3

Срабатывает ли покрывающий индекс (индекс на a, b, c)?

select a, b from tbl where a=0 and b=3

select a,b,c from tbl where a=0 and b=3

select a,b,c,d from tbl where a=0 and b=3

select a,b,c,id from tbl where a=0 and b=3

EXPLAIN

QUERY PLAN

Index Only Scan using a_b_c on tbl (cost=0.42..7.90 rows=199 width=16) (actual time=1.453..1.574 rows=202 loops=1) Index Cond: (a = 60)

Heap Fetches: 0 Planning Time: 0.996 ms Execution Time: 1.686 ms

(5 rows)

Виды проходов по индексу

- Seq Scan последовательный просмотр таблицы
- Index Scan просмотр по индексу и в таблице
- Index Only Scan просмотр по индексу без обращения к таблице
- Bitmap Heap Scan оптимизация с построения битовых карт для поиска

Сортировка

Хорошие запросы:

select * from tbl

- order by a limit 10;
- where a=1 order by b limit 10;
- where a>0 order by a limit 10;
- order by a desc, b desc limit 10;
- order by a asc, b asc limit 10;

Когда индексы не работают

- Часть выражения: а + 1 = 3, а = func(2)
- Преобразование типов: str = 1
- Несоответствие кодировок
- Индекс не существует или невалидный
- Используется дубликат этого индекса

Как выбирается индекс

- План выбирается динамически с учетом «костов»
- Использование таблицы статистики

Доп.материал

-- Простой индекс

https://www.db-fiddle.com/f/chBbJBYj6GMdyqCxXLBPEG/1

-- Уникальный индекс

https://www.db-fiddle.com/f/4FcEUB9zDZZWnkcJLvEqUq/2

-- Составной индекс

https://www.db-fiddle.com/f/v4KvbgaVVD4NDDjCBg4x5f/1

-- особенности использования 2 и далее индексов в составном

https://www.db-fiddle.com/f/v4KvbgaVVD4NDDjCBg4x5f/3

Доп.материал

-- Покрывающий индекс

https://www.db-fiddle.com/f/33g3xrNmhpCt3a65rEUJJf/1

-- Функциональный индекс

https://www.db-fiddle.com/f/TZpqd6F4zofvbGCn1TOaR/0

-- Частичный индекс

https://www.db-fiddle.com/f/8bJbb6bZUTD8mQpg5v7Wvd/0

Д3 №4

https://github.com/DWH-course-examples/SQL-postgres/blob/main/homework/task4.md

СПАСИБО ЗА ВНИМАНИЕ!